以动作生成为例，讨论 exposure bias 在连续空间的解决方案

不管在连续还是离散空间，进行序列化的生成都会存在的一个问题是 exposure bias。

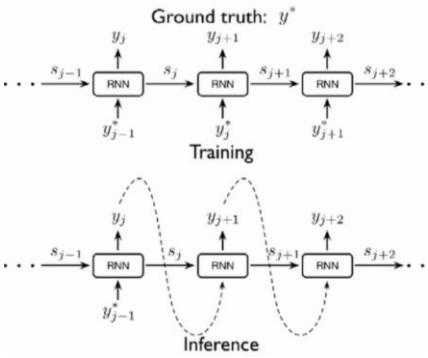


这个问题是因为在训练的时候以 ground truth 作为 decoder 的输入，而在测试的时候自回归的生成，从而造成了不一致，在测试时，一旦某一个 step 预测出现了偏差，这个偏差就会累积。在离散空间中，以常见的文本生成为例，常见的解决方案有以下几种:

1. beam search

这种方法试图对整个生成的序列找到最优解，而不是只考虑当前词最优。是一种图路径搜索算法，搜索的过程中保存 beam size 个整体得分最高路径，剪掉其他路径，直到达到设定的步数 n。比如下图，生成从 F 开始的长度为 n 得分最高的路径。

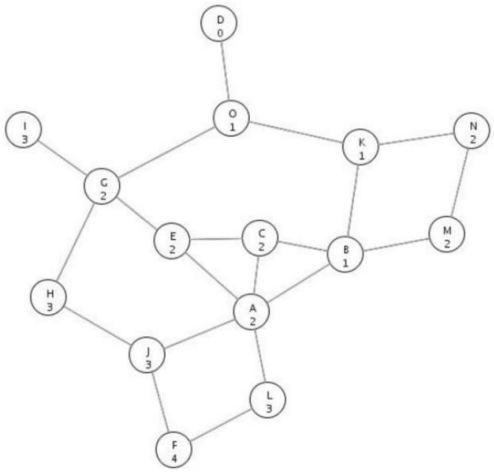


在文本生成问题中，token 的分值即为概率值。在训练集中仍然使用 ground truth 作为 decoder 的输入，在测试集中，使用 beam search，相当于要产生使整个句子概率最大的最优解（贪心算法，局部最优），而非每一步都要选择概率最大的词，导致生成的句子可能偏差很大。

2. schedule sampling

在训练过程中，早期主要使用 ground truth 作为 decoder 的输入，随着训练进行，逐渐更多的使用上一步产生的 token。这样即使前面生成错误，仍以生成正确的序列为训练目标产生后面的 token，增大了模型的容错能力。

与这种方法类似的是直接将加了噪音的 ground truth 作为输入进行训练，可以使得模型具有一定的抗噪能力。

3. reinforcement learning

使用强化学习解决能够这个问题，是由于训练模型时，每次选择的是使得整个后续的序列最好的 action（q value 最大），而非仅仅考虑当前词。此时训练集的输入为上一个产生

的 token。不同于而上述两种方法，rl 方法在文本中往往不是以重建作为目标（不是 seq2seq），而是以与任务相关的评分函数为 reward，比如翻译任务中的 bleu 值，生成任务中判别器给出的真实概率值。由于离散空间的生成涉及到采样过程，nlp 中一般会使用 policy gradient 或者 actor-critic 等方法进行学习。

现在考虑我们要在连续的动作的空间进行序列化生成，此时会面临着更严重的 exposure bias 问题，首先动作（human motion）生成的步数是远远多于文本的，一个句子最长也在几十个词之内，而我们希望能够产生上千帧的动作；其次，在离散空间，概率向量的偏差可以通过采样修正（[0,0,1]和[0.3,0.3,0.4]都可以产生正确的 id 为 2 的采样），而在连续空间任意一点小的偏差都会累积。

而在离散空间的三种方法，第一种显然是无法迁移的，因为不在是在有限个离散点进行采样，就称不上是图路径搜索了。比较常见的是第二种方法，下面我们结合几篇文章来看。

Recurrent Network Models for Human Dynamics （ICCV2015）

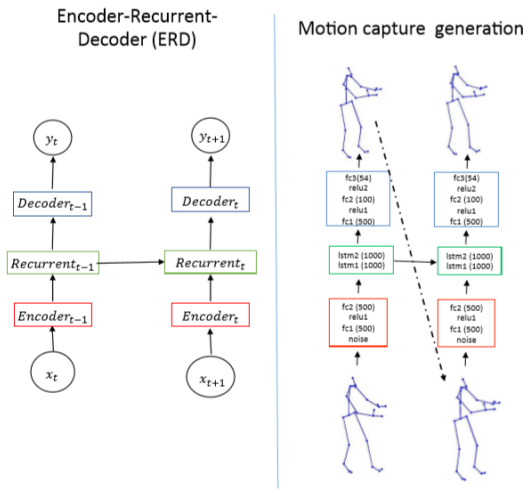


本文模型非常简单，仅仅是在 RNN 的基础上增加了一些全连接层增加模型的表达能力。对于 exposure bias 问题，本文采取的方法是在 ground truth 上增加了以 0 为均值的高斯噪音，并逐渐增加方差，属于 curriculum learning。

On human motion prediction using recurrent neural networks(CVPR2017)

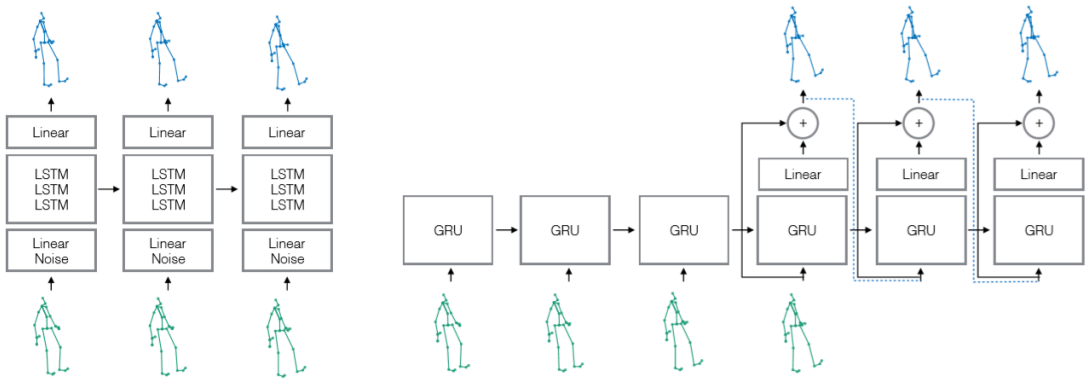


对比上一篇文章，本文有以下几点改进：

首先，本文认为使用加噪音的方法面临着超参数调参的问题，因此本文直接提出，用每次从生成的动作空间采样作为下次预测的输入。第二点，本文提出了一个非常有效的结构，即从 rnn 输入到输出的残差连接。人对 motion 的连贯性是有常识的，但是对于网络来说，每次都要在整个 motion 空间中进行预测，如果由残差连接来直接保留上一帧的动作，在此

基础上预测某些关节点的移动，是一个更加简单的目标。第三点，整个框架被设计为了 seq2seq 结构，由前面时间段的 motion 作为 encoder 输入，去预测后面时间的动作。

AUTO-CONDITIONED RECURRENT NETWORKS FOR EXTENDED COMPLEX HUMAN MOTION SYNTHESIS（ICLR 2018）

本文的方案稍微有别于 schedule sampling，通过直接固定一个间隔，来以 gt/上次输出作为输入：

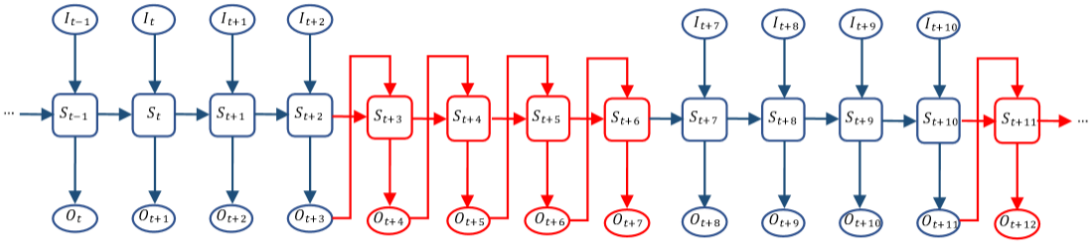


而还没有人尝试过的一个方向就是在连续空间中使用类似于 rl 的方法。最简单的实现是在 train 的阶段就将输出作为下次输入，并且允许梯度顺着这个输入输出进行传递。由于上述工作都是在 3D 空间中的，这时 human motion 的特征不在连续空间中（某节点相对于父节点的角度，不是完整的实数空间），所以这个梯度不会这样回传，而在 2D 空间中是可以的。此时问题可以看做是 model based rl 问题，reward function 就是每个生成的 motion 和真实 motion 的距离，p(s2|s1,a)=1，因此变成了优化控制的问题，学习的目标是选择一系列动作让总体的损失最低：

$$\min_{u_1,\ldots,u_T} \sum_{t=1}^{T} c(x_t, u_t), s.t. x_t = f(x_{t-1}, u_{t-1})$$

写成无限制的优化问题为：

$$\min_{u_1,\ldots,u_T} c(x_1, u_1) + c(f(x_1, u_1), u_2) + \ldots + c(f(f(\ldots)\ldots), u_T)$$